ML Pipeline & MLOps cho dự báo bán lẻ

Tiếp nối Assignment 1: dự báo bảy ngày,
đơn nháp có người duyệt.

Thiết kế

Pipeline 25%
Điều phối Airflow 20%

Thực nghiệm

Tracking & metrics 25%
10 cấu hình, chọn trước test

Tái lập

Chất lượng mã 20%
Versioning 10%

Kết quả dùng dữ liệu mô phỏng; không phải bằng chứng triển khai doanh nghiệp.

Bài toán và ràng buộc từ Assignment 1

Quy mô đích

20 cửa hàng × 2.000 SKU
40.000 cặp
280.000 forecast/ngày

Quyết định

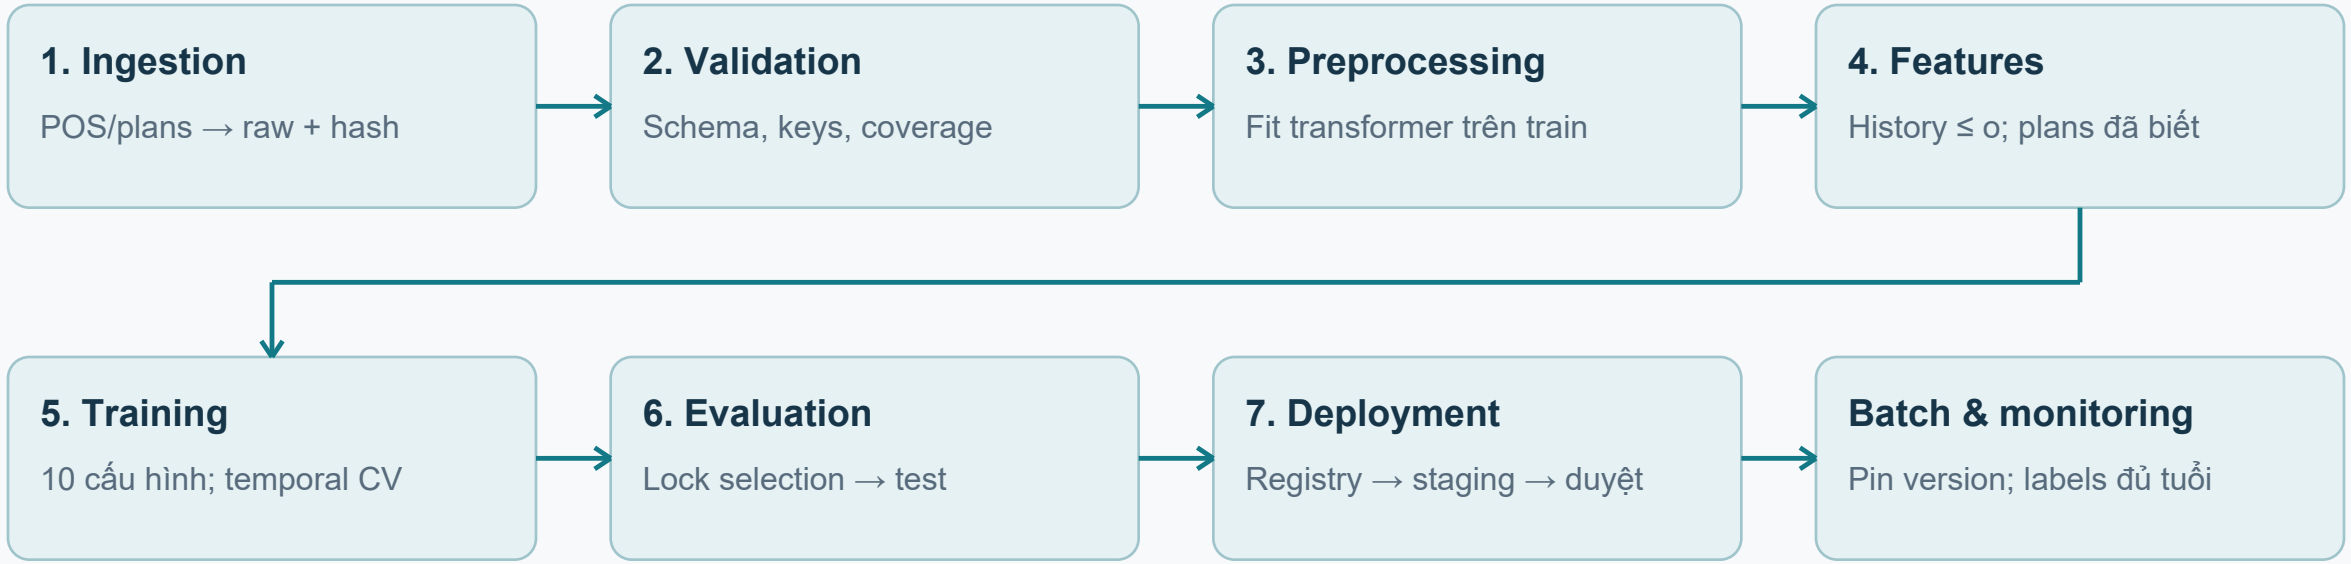
Một mô hình dùng chung
Dự báo h = 1…7
Đơn nháp → người duyệt

Thời gian

Cutoff dữ liệu 01:00
Công bố trước 05:30
Ngày gốc o = D−1

Mục tiêu: giảm hết hàng và tồn kho dư. Sai số forecast là chỉ số trung gian; tác động kinh doanh vẫn cần pilot có nhóm đối chứng.

Pipeline: đủ bảy stage và cổng chất lượng



Gates: dữ liệu hợp lệ → model đạt ngưỡng → ops/shadow đạt → người duyệt release.

Module tái sử dụng; partition theo cửa hàng; lỗi dữ liệu cách ly, lỗi tạm thời retry; rollback version.

Đánh giá đúng thời gian, đúng mục tiêu

Protocol chống leakage

CV: tháng 01 / 02 / 03–2025
Test khóa: tháng 04–06–2025
Purge toàn bộ origin; fit trên train
Không dùng target sales/availability làm feature

Metrics và gates

Primary: WAPE ≤25%; cải thiện ≥10%
Bias tuyệt đối ≤5%
Nhóm không xấu hơn baseline >2 điểm %
Secondary: MAE, RMSE, MASE, coverage, time

$$WAPE = 100 \times \Sigma|y-f| / \Sigma y;\ bias = 100 \times \Sigma(f-y) / \Sigma y.$$

WAPE tốt chưa chứng minh giảm hết hàng: còn phụ thuộc tồn kho, lead time và chính sách đặt hàng.

Mười cấu hình có baseline và ablation

ID	Cấu hình	Mục đích
E01	Mean 28 ngày	Baseline chính sách hiện tại
E02	Cùng thứ 4 tuần	Baseline mùa vụ
E03	Mùa vụ + promo	Hệ số promo chỉ học trên train
E04	Ridge; alpha=10	Đối chiếu mô hình đơn giản
E05	Poisson; 31 lá; lr=0,05	LightGBM ứng viên chuẩn
E06	Poisson; 15 lá; lr=0,05	Giảm capacity so E05
E07	Poisson; 63 lá; lr=0,05	Tăng capacity so E05
E08	Poisson; 31 lá; lr=0,10	Đổi learning rate so E05
E09	L1; 31 lá; lr=0,05	Đổi objective so E05
E10	Poisson; bỏ promo/price	Ablation khuyến mãi so E05

Cùng split/mask; LightGBM: 200 cây, 2 luồng, seed=501. Preprocessing học riêng từng fold.

Validation: E05 cân bằng sai số và độ phức tạp

ID	WAPE pooled %	Bias %	SD 3 fold
E01	23.429	-2.065	0.119
E02	22.599	-2.079	0.386
E03	19.543	+4.487	0.407
E04	16.018	-4.314	0.324
E05	**15.705**	**-2.271**	**0.371**
E06	15.734	-2.179	0.447
E07	15.755	-2.355	0.370
E08	15.715	-2.385	0.417
E09	15.850	-3.051	0.353
E10	20.555	-2.267	0.467

Chọn cấu hình bằng validation; các model dùng cùng dòng nhãn đủ điều kiện.

Candidate E05

Poisson · 31 lá · lr=0,05
WAPE validation: 15,705%
Baseline tốt nhất: E03 — 19,543%

Bỏ promo/price: WAPE tăng 4.851 điểm %.
63 lá không cải thiện so với 31 lá.
Ridge nhanh hơn; chênh nhỏ giữa các LGBM không chứng minh ưu thế thống kê chắc chắn.

Locked test: candidate vượt baseline đã khóa

Model	WAPE %	Bias %	MASE
E03	20.159	+6.738	0.750
E05	**15.837**	**-2.554**	**0.591**

21,44%

Cải thiện WAPE tương đối
Model gate đạt
Bias E05: −2,55%

3.884 / 4.032

Dòng nhãn đủ điều kiện
Coverage nhãn: 96,33%
Không phải serving coverage

Bất định

ΔWAPE E05−E03: −4,322 pp
Bootstrap 95%: [-4.74; -3.85]
12 block tuần; chỉ mô phỏng

Khuyến nghị E05 làm candidate nghiên cứu; chưa cho phép phát hành production.

Nguồn: test_results.json; test_slices.csv

Airflow: tách inference ngày và candidate tuần

DAG ngày: ingest → validate → features → predict → gate → publish

DAG tuần: snapshot/split → train/CV → lock/evaluate → registry → review

Schedule

Ngày: chốt 01:00
Cảnh báo nếu trễ 03:30
Deadline 05:30
Candidate: Chủ nhật 01:00

Recovery

Retry lỗi tạm thời + backoff
Lỗi dữ liệu → quarantine
Task timeout; rollback
XCom chỉ mang artifact URI

Monitoring

Task/time/freshness/coverage
WAPE/bias khi nhãn đủ tuổi
Drift → điều tra
Alert có owner và runbook

DAG demo: prepare → search → evaluate → register; đã kiểm tra cú pháp, chưa chạy scheduler.

CODE QUALITY 20% · REPRODUCIBILITY 10%

Mã gọn, cấu hình rõ, lineage có thể tái lập

Chất lượng mã & MLflow

Style, docstrings, type hints, comments
Config JSON + environment overrides
Log params/metrics/artifacts/signature
30 fold runs + 1 final run thành công
8 tests; registry roundtrip không đổi prediction

Code / data / model versioning

Git branch → review → release tag (thiết kế)
Snapshot SHA-256 + split/config/source hashes
Registry version + demo_candidate, pin khi serving
Seed=501; package lock; Dockerfile
Không thay champion từ dữ liệu mô phỏng

Báo cáo chỉ giữ snippets bắt buộc: MLflow, DAG/tasks/dependencies, config, seed, Git, Dockerfile.

Airflow integration và Docker build chưa thực hiện; seed không bảo đảm giống hệt mọi phần cứng.

Quyết định và giới hạn bằng chứng

Đã có bằng chứng

Pipeline đầy đủ, stage gates, recovery
10 cấu hình + baseline + trade-offs
Selection trước locked test
MLflow logging/registry thực chạy
E05 là candidate phù hợp protocol này

Cần trước production

Dữ liệu thực và replay origin hằng ngày
Kiểm tra tải, Airflow/Docker và recovery
Shadow + ops gate + người duyệt
Pilot có đối chứng đo stockout/tồn kho
Không suy diễn WAPE thành lợi ích kinh doanh

Demo: 48 chuỗi; một seed; origin cách bảy ngày; chưa đại diện đầy đủ vận hành thực.

Nguồn phương pháp: Forecasting: Principles and Practice; MLflow; Airflow; LightGBM.
Trích dẫn chi tiết và toàn bộ kết quả nằm trong báo cáo Assignment 2.